

**İnsansız Hava Araçları Teknolojisi ile Orman
Yangınlarının Tespiti**

Dilara Karadaş

Deniz Uzunyol

Bitirme Projesi

Bilgisayar Mühendisliği Bölümü

Güliz Toz

Kasım 2024

**T.C.
KARAMANOĞLU MEHMETBEY ÜNİVERSİTESİ
MÜHENDİSLİK FAKÜLTESİ**

İnsansız Hava Araçları Teknolojisi ile Orman Yangınlarının Tespiti

**BİTİRME PROJESİ
Dilara KARADAŞ
Deniz UZUNYOL**

BİLGİSAYAR MÜHENDİSLİĞİ

Tez Danışmanı: Dr. Öğr. Üyesi Güliz TOZ

KARAMAN 2024

TEZ ONAYI

Dilara Karadař ve Deniz Uzunyol tarafından hazırlanan İnsansız Hava Araçları Teknolojisi ile Orman Yangınlarının Tespiti adlı çalışma ařağıdaki jüri tarafından oy birliğı / oy çokluğu ile Karamanoğılu Mehmetbey Üniversitesi Mühendislik Fakóltesi Bilgisayar Mühendisliğı Bitirme Projesi Tezi olarak kabul edilmiştir.

Danışman:

Dr. Öğr. Üyesi Güliz TOZ

Jüri Üyeleri:

İmza:

Tez Savunma Tarihi:...../...../.....

TEZ BİLDİRİMİ

Yazım kurallarına uygun olarak hazırlanan bu tezin yazılmasında bilimsel ahlak kurallarına uyulduğunu, başkalarının eserlerinden yararlanılmasında bilimsel normlara uygun olarak atıfta bulunulduğunu beyan ederim.

Dilara KARADAŞ

Deniz UZUNYOL

ÖZET

BİTİRME PROJESİ TEZİ

İnsansız Hava Araçları Teknolojisi ile Orman Yangınlarının Tespiti

Dilara KARADAŞ
Deniz UZUNYOL

Karamanoğlu Mehmetbey Üniversitesi
Mühendislik Fakültesi
Bilgisayar Mühendisliği Bölümü

Danışman: Dr. Öğr. Üyesi Güliz TOZ
Kasım 2024

Bu proje, orman yangınlarının erken teşhisine yönelik mevcut yöntemleri geliştirmeyi ve Türkiye ile dünya genelinde uygulamalarını artırmayı hedeflemektedir. Yangınların zamanında tespit edilmesi, büyük zararlara yol açmadan kontrol altına alınmasına olanak tanır; bu da orman alanlarının yeniden yetiştirilmesinde yaşanacak kaybı en aza indirir ve maliyetleri düşürür. Projede, veri setlerinden ve insansız hava araçlarından elde edilen görüntüler ve videolar, farklı makine öğrenimi ve derin öğrenme yöntemleri ile üzerinde eğitilecek ve test edilecektir. Özellikle Lojistik Regresyon, Destek Vektör Makineleri, Rastgele Orman gibi algoritmaların yanı sıra YOLO gibi derin öğrenme modelleri ile yangın tespit sistemlerinin etkinliği artırılacaktır. Aynı zamanda, proje kapsamında elde edilen sonuçlar, bilimsel bir yayın olarak sunulacaktır. Projenin yerel ve ulusal ekonominin korunmasına, insan yaşamının güvence altına alınmasına ve toplumsal dayanışmanın güçlenmesine yardımcı olacak önemli sosyal ve ekonomik faydaları olacağına inanılmaktadır.

Anahtar Kelimeler: Derin Öğrenme, İnsansız Hava Araçları, Erken Yangın Tespiti, Makine Öğrenmesi

ÖNSÖZ

Bu tez çalışması, yangın tespiti konusundaki mevcut yaklaşımları anlamaya yönelik olarak gerçekleştirilmiş bir araştırma sürecinin ürünüdür. Çalışma boyunca temel amacımız, bu alanda kullanılan yöntemler, teknolojiler ve güncel literatürdeki yaklaşımlar hakkında kapsamlı bir bilgi edinmek ve bu bilgileri sistematik bir şekilde derleyerek sunmaktır. Alanın dinamik yapısı ve teknik çeşitliliği göz önüne alındığında, bu çalışmanın, ileride yapılacak uygulamalı çalışmalara zemin hazırlayabileceğine inanıyorum.

Tez süreci boyunca birçok kişinin bilgi, destek ve motivasyon anlamında katkısını hissettim. Öncelikle, tez danışmanım **Dr. Öğr. Üyesi Güliz Hoca'ya**, akademik yolculuğumun her aşamasında bana gösterdiği sabır, rehberlik ve anlayış için en içten teşekkürlerimi sunuyorum. Kendisi, yalnızca bu çalışmanın yönünü bulmasında değil, aynı zamanda akademik düşünme becerilerimin gelişmesinde de önemli bir rol oynamıştır.

Ayrıca, bu süreçte birlikte çalıştığım proje arkadaşım **Deniz Uzunyol'a** teşekkür etmek isterim. Her aşamada karşılıklı fikir alışverişinde bulunarak, motivasyonumuzu koruyarak ve araştırma sürecine birlikte katkı sağlayarak bu çalışmanın ilerlemesini mümkün kıldık.

Bu tez, herhangi bir kurumsal proje kapsamında desteklenmemiştir.

Dilara Karadaş

Karaman 2025


İÇİNDEKİLER

İçindekiler Tablosu


ÖZET.....	1
ÖNSÖZ	2
İÇİNDEKİLER.....	3
1. GİRİŞ.....	1
1.1. Türkiye’de Orman Yangını.....	1
1.2. İnsansız Hava Araçları Teknolojisi.....	2
1.3. Yapay Zeka Teknolojisi.....	2
2. MATERYAL VE METOT	4
2.1. Literatür Taraması.....	4
3. İş-Zaman Çizelgesi.....	11
4. Deneysel Çalışmalar.....	12
4.1. Yangın Tespiti İçin Derin Öğrenme Modelleri: VGG16 ve ResNet50 Performans Karşılaştırması.....	16
Model Mimarilerinin Teorik Altyapısı.....	16
4.2. Model Özelleştirme ve Eğitim Süreci.....	16
4.4. YOLOv11 Performans Değerlendirmesi.....	18
4.5. YOLOv1 İçin Sonuç ve Öneriler.....	20
5. Deneysel Çalışmalar.....	21
6. Sonuç ve Öneriler	23
7. Sonuç ve Öneriler	24
KAYNAKLAR	25

1. GİRİŞ

Ormanlar, insanlığa sundukları gıda, yakıt, barınak, temiz hava ve su gibi maddi faydaların yanı sıra, gelir kaynağı, istihdam, dinlenme ve peyzaj gibi birçok ekonomik, ekolojik ve sosyokültürel fayda sağlayan önemli doğal kaynaklardır. Bir ekosistem olarak ormanlar, ağaçlar, diğer bitki ve hayvan toplulukları ile toprakta yaşayan organizmaların cansız çevre ile dengeli bir etkileşimde bulunduğu canlı sistemlerdir [1]. Bu sistemin yok olması pek çok canlının yaşam alanının yok olması, var olan ekolojik dengenin bozulması, hava kirliliği oluşması, sel ve heyelan gibi doğal afetlerin önünün açılmasına sebep olmaktadır. Şekil 1’de 2018-2021 yılları arasında dünya üzerinde bulunan bazı ülkelere ve Türkiye’ye ait çıkan orman yangınlarında yanan alan miktarı (hektar cinsinden) ve Şekil 2’de 2021 yılında orman yangınları nedeniyle salınan CO_2 emisyonları (1,000 ton cinsinden) görülebilir [3].



Şekil 1. 2018-2021 yılları arasında bazı ülkelerde orman yangınlarında yanan alan miktarı (hektar) [3]




Şekil 2. 2021 yılında çıkan orman çıkan yangınları nedeniyle salınan CO_2 emisyonları (1000 ton)[3]

1.1.Türkiye’de Orman Yangını

Türkiye’de ormanların büyük çoğunluğu, Orman Genel Müdürlüğü tarafından sürdürülebilirlik esaslarına göre yönetilmekte ve tüm ormanlar orman amenajman planlarına göre işletilmektedir (Orman Kanunu, Madde 26). 2022 yılı itibariyle Türkiye’nin toplam orman alanı 23.245.000 ha’dır. Bu orman alan miktarı ülke genel alan toplamının %29,8’i kadardır [2].

Bilindiği gibi dünyada ve yurdumuzda her yıl çok sayıda orman yangını çıkmakta, bunların bir kısmı yangın başlangıcında söndürülebilirken, bir kısmı ise rüzgar gibi dış etkenlerle daha da büyüyerek önemli zararlara sebep olmaktadır. Erken müdahale ile yangınların büyümeden önüne geçmek mümkündür, aksi durumda yangınlar insanların

yaşam alanına kadar ilerleyip doğrudan insan hayatı için tehlike oluşturabilmektedir. Örneğin Avusturalya'da 2020 yılında çıkan yangında 34 kişi doğrudan vefat etmiştir [4]. Ayrıca, Tasmanya Üniversitesi Menzies Tıbbi Araştırma Enstitüsü'nden Johnston, dumandan dolayı yaklaşık 445 kişinin öldüğünü, 3.000'den fazla kişinin solunum problemleri nedeniyle hastaneye kaldırıldığını ve 1.700 kişinin astım nedeniyle hastaneye kaldırıldığını tahmin ettiğini bildirmiştir [5]. Bu yangında yaklaşık 3 milyardan fazla yerel omurgalı, 143 milyon memeli, 2,46 milyar sürüngen, 181 milyon kuş, 51 milyon kurbağa yanarken, ülke nüfusunun yaklaşık %80'ini etkileyen bu yangın, 9,352 yapıyı yok etmiştir [6]. Aynı zamanda bu yangının 434 milyon ton karbondioksit gazı saldığı ve Güneydoğu Avustralya'da yağışta %61'lik bir düşüş gözlemlendiği bildirilmiştir [7]. Bu yangının mali zararı ise 2,2 milyar dolar olmuştur [8].



Şekil 3. Avrupa Orman Yangını Bilgi Sistemine göre 2006-2024 yılları arasında Türkiye'de çıkan orman yangınlarının grafiği [10]

1.2.İnsansız Hava Araçları Teknolojisi

İnsansız Hava Araçları, uzaktan kumanda edilen veya önceden programlanmış rotalarda otomatik olarak uçabilen hava araçlarıdır. İlk olarak askeri amaçlarla geliştirilen bu araçlar, günümüzde birçok farklı sektörde kullanılmaktadır. Özellikle sivil havacılıkta ve ticari alanlarda yaygınlaşan insansız hava araçları, küçük boyutları, manevra kabiliyetleri ve çeşitli sensörlerle donatılmaları sayesinde farklı amaçlar için uyarlanabilir. İnsansız hava araçlarının, GPS ve Wi-Fi gibi teknolojilerle yönlendirilmesi ve yüksek çözünürlüklü kameralarla donatılması, onları havadan görüntüleme ve veri toplama süreçlerinde önemli bir araç haline getirmiştir [10].

1.3.Yapay Zeka Teknolojisi

Yapay zekâ, makinelerin insan gibi düşünüp karar verme yetenekleri kazanmasını sağlayan algoritmaların, özellikle de derin öğrenme gibi gelişmiş modellerin kullanılmasıyla oluşturulan bir bilim dalıdır [11]. Yapay zekânın en önemli uygulama alanlarından biri olan görüntü işleme, görsel verilerin analiz edilerek anlamlandırılması sürecidir. Görüntü işleme yöntemlerinden, tıbbi görüntüleme sistemlerinde hastalık teşhisi, akıllı cihazlar yüz tanıma teknolojileriyle kimlik doğrulama işlemleri gibi pek

çok farklı alanda faydalanılmaktadır. Biz de bu çalışmada ve ormanlık alanlarda duman ve yangınların tespiti amacıyla görüntü işleme, makine öğrenmesi ve derin öğrenme yöntemlerinden faydalanacağız.

2. MATERYAL VE METOT

Bu projede, orman yangınlarının erken tespiti ve hızlı müdahale süreçlerini iyileştirmek amacıyla insansız hava araçları, görüntü işleme teknikleri ve yapay zekâya dayalı bir sistem önerilmektedir.

Modelin başarısını ölçmek amacıyla aşağıda detaylandırılan dört temel ölçüt kullanılmıştır:

Doğruluk, modelin tüm tahminleri içerisinde doğru olarak sınıflandırdığı örneklerin oranını ifade eder. En temel başarı ölçütlerinden biridir ve şu şekilde hesaplanır:

$$Accuracy = (TP + TN) / (TP + TN + FP + FN)$$

Ancak veri dengesizliğinin olduğu durumlarda yanıltıcı olabileceği için diğer ölçütlerle birlikte değerlendirilmelidir.

Hassasiyet, modelin pozitif (yangın) olarak tahmin ettiği örneklerin gerçekten pozitif olma oranını gösterir. Özellikle yangın gibi kritik durumların yanlış pozitiflerle değerlendirilmesini engellemek açısından önemlidir.

$$Precision = TP / (TP + FP)$$

Duyarlılık, modelin gerçek pozitif sınıfları ne kadar doğru tahmin edebildiğini gösterir. Yangın tespiti gibi kritik uygulamalarda yangının gözden kaçırılmaması gerektiği için yüksek duyarlılık büyük önem taşır.

$$Recall = TP / (TP + FN)$$

F1-Skoru, hassasiyet ve duyarlılık değerlerinin harmonik ortalamasıdır. Bu ölçüt, özellikle dengesiz veri setlerinde modelin genel performansını daha adil bir şekilde değerlendirmek için kullanılır.

$$F1 = 2 * (Precision * Recall) / (Precision + Recall)$$

2.1.Literatür Taraması

Literatürdeki yangın ve duman tespitine yönelik çalışmalar incelendiğinde, orman yangınlarının otomatik tespitine yönelik ilk çalışmalardan biri Chen ve arkadaşları[12] tarafından gerçekleştirilmiştir. Bu çalışmada, **FLAME2** veri seti kullanılmıştır. FLAME2, 2021 yılında Flagstaff, Arizona yakınlarında gerçekleştirilen bir kontrollü yangın sırasında toplanan **RGB/IR yan yana görüntülerini** içeren özel bir veri setidir; çift kanal RGB/IR drone videoları ve görüntülerinden oluşmaktadır. Veri seti, **yangın/no-yangın** ve **duman/no-duman** etiketleriyle sınıflandırılmış olan görüntüleri içermektedir. Bu etiketleme işlemi, iki insan uzmanı tarafından yapılmış olup, veri setinin yangın tespiti ve modelleme gibi alanlardaki potansiyel uygulamalarını genişletmektedir. Ayrıca, veri setine **hava durumu bilgileri** ve **coğrafi referanslı ön**

yangın nokta bulutu verileri de dahil edilmiştir. Bu veriler, yangın yayılma modeli ve yangın sonrası sıcaklık haritaları gibi yüksek çözünürlüklü analizlerin yapılmasına olanak sağlamaktadır. Bu çalışmada, **derin öğrenme tabanlı (DL)** yöntemler kullanılmıştır. Özellikle, **RGB-termal füzyonunu** kullanarak **hızlı yangın sınıflandırması** yapılmış ve **karşılaştırmalı analiz** gerçekleştirilmiştir. Ayrıca, **hibrit bir yöntem** geliştirilmiştir. Bu hibrit yöntem, **derin öğrenme tabanlı sınıflandırıcı** ve **yangın tespiti yerelleştirmeyi** birleştirerek, **iki kanallı (dual-feed) görüntülerle** işlem yapmaktadır. **Transfer Learning** yaklaşımı da kullanılarak, önceden **ImageNet** gibi büyük veri setlerinde eğitilmiş derin öğrenme modelleri üzerine ince ayar yapılmıştır. Bu sayede, yeni veri setiyle uyumlu modellerin hızla eğitilmesi sağlanmıştır. Çalışmada kullanılan derin öğrenme mimarileri, **CNN tabanlı ağlar** olup, yangın tespiti için özel olarak optimize edilmiştir. Aşağıdaki tabloda bu çalışmanın sonucu olarak farklı modellerin ve modların ortalama performanslarının karşılaştırılması görülmektedir. '*' işaretiyle belirtilen modeller, ince ayar yapılmış önceden eğitilmiş modellere işaret etmektedir.

Model	Mode	F1 Score	Precision	Recall	Accuracy
Logistic	RGB	89.57	90.99	89.48	90.37
Logistic	IR	92.61	92.94	92.43	92.43
Logistic	Early Fusion	96.71	96.92	96.65	96.54
LeNet5	RGB	95.39	95.86	95.12	95.33
LeNet5	IR	92.3	92.19	92.79	92.15
LeNet5	Early Fusion	97.16	97.35	97.1	97.01
LeNet5	Late Fusion	98.45	98.35	98.58	98.32
Flame	RGB	94.53	95.18	94.38	94.86
Flame	IR	86.81	87.47	86.91	85.79
Flame	Early Fusion	95.67	96.17	95.26	95.70
Flame	Late Fusion	98.63	98.76	98.52	98.60
VGG16*	RGB	99.92	99.9	99.93	99.91
VGG16*	IR	97.35	97.57	97.26	97.29
MobileNetV2*	RGB	99.36	99.33	99.42	99.35
MobileNetV2*	IR	97.51	97.65	97.43	97.38
MobileNetV2*	Late Fusion	99.82	99.78	99.87	99.81
ResNet18*	RGB	98.46	98.57	98.37	98.32
ResNet18*	IR	96.54	96.97	96.27	96.26
ResNet18*	Late Fusion	99.5	99.46	99.56	99.44

Şekil 4. Chen ve çalışma arkadaşlarının yaptığı çalışma sonuçları.

Shi ve arkadaşları[13] ise orman yangınlarını tespit etmek için yapılan çalışmada, orman yangınları ve duman tespiti amacıyla internetten derlenen 7878 görüntü örneğinden oluşan bir veri seti kullanılmıştır ve modelin performansını iyileştirmek amacıyla çeşitli **önişleme adımları** uygulanmıştır. Bu çalışmada, **YOLOv5m** tabanlı bir model kullanılmıştır. Modelin başarısını artırmak amacıyla, **SAC (Switchable Atrous Convolution)**, **PSA (Polarized Self-Attention)** ve **Soft-NMS** gibi modüller eklenerek geliştirilmiştir. SAC, geleneksel konvolüsyonları geliştirerek, modelin arka plan bilgilerini daha iyi öğrenmesini ve daha hızlı bir şekilde eğitim almasını sağlamaktadır. PSA, özellikle duman ve alev gibi küçük ve geniş alanlara yayılan nesnelerin tespitinde modelin performansını iyileştiren bir modül olarak kullanılmıştır. Ayrıca, Soft-NMS, geleneksel NMS yöntemine kıyasla daha doğru hedef tespiti ve daha az yanlış pozitif sağlar. Modelde, **YOLOv5**'in backbone yapısı olan **CSPDarknet53** kullanılarak özellik çıkarımı yapılmıştır. Aşağıdaki tabloda ise çalışmanın farklı modüller ile sonuçları görülmektedir.

Model	mAP ⁵⁰ (%)	mAP ⁷⁵ (%)	R (%)	FLOPs (G)	FPS
YOLOv5	77.8	54.0	71.2	47.9	65
YOLOv5 + SAC	78.5	53.1	73.7	30.9	47
YOLOv5 + SAC + Soft-NMS	78.8	58.9	73.7	30.9	45
SPS-YOLOv5	79.8	58.3	74.3	31.7	43

Şekil 5. Shi ve çalışma arkadaşlarının yaptığı çalışma sonuçları.

Bir diğer çalışma Engin ve Kökhan tarafından gerçekleştirilmiştir [14]. Yapılan çalışmada, **Kaggle yangın veri tabanı** kullanılmıştır. Veri tabanı, **755 adet ateşli görüntü (yangın var)** ve **244 adet ateşsiz görüntü (yangın yok)** içermektedir. Bu veri seti, farklı çözünürlük ve renk uzaylarına sahip imgeler içerdiğinden, tüm görüntüler aynı çözünürlükte ve renk uzayında standartlaştırılmıştır (256x256 piksel, RGB renk uzayı). İlk olarak veri setinden alınan görüntülere bölütleme tekniği uygulanmış, ardından siyah beyaz renk dönüşümü yapılmıştır ayrıca ormanlık alanda tarama yapacak insansız hava araçlarının tüm alanları kapsayacak şekilde uygun rotalarda uçabilmesi için uygun geçiş koordinatları küme kapsama yöntemi kullanılarak tespit edilmiştir. VGG16, AlexNet, InceptionV3 ve Resnet50 mimarileri, aktarım öğrenme tekniği kullanılarak sınıflandırma modeli eğitilmiştir. En iyi sonuç **VGG16** modelinde alınmıştır. Bu modelin test veri kümesi ile elde edilen sonuçlar şu şekildedir:

Performans Ölçütü	Değer(%)
Doğruluk (Accuracy)	97.51
Duyarlılık (Recall)	98.04
Özgüllük (Specificity)	95.83
Kesinlik (Precision)	98.68
F1 Skoru	98.

Tablo 1. Engin ve Kökhan tarafından yapılan çalışmanın detayları.

Aksoy ve arkadaşları[11] bu çalışmada, yangın tespiti için **Kaggle** adlı açık erişim internet sitesinden alınan **FIRE-Dataset** adlı veri seti kullanılmıştır. Veri seti, **755 yangın içeren** ve **244 yangın içermeyen** görüntüden oluşmaktadır. Görüntü ön işleme aşamasında, verilerin kalitesini artırmak için birkaç önemli adım uygulanmıştır. İlk olarak, görüntülerin gürültüsünü azaltmak ve detayları yumuşatmak amacıyla **Gaussian filtreleme** işlemi gerçekleştirilmiştir. Ardından, nesneleri arka plandan ayırmak için **eşikleme** yöntemi uygulanmış ve görüntülerin boyutları uygun hale getirilerek modele giriş için optimize edilmiştir. Yangın tespiti yapmak için **SqueezeNet** evrimsel sinir ağı (CNN) modeli kullanılmıştır. SqueezeNet, daha düşük parametre sayısı ile yüksek doğruluk sağlama yeteneğine sahip bir modeldir ve bu özellikleri nedeniyle tercih edilmiştir. Öğrenme oranı **0.005** olarak belirlenmiş ve **epoch sayısı 10** olarak ayarlanmıştır. Çalışmada, **SqueezeNet** modelinin performansı aşağıdaki gibi değerlendirilmiştir:

Model	Doğruluk(%)	Duyarlılık(%)	Kesinlik(%)	F-Skor(%)
Firenet	93.91	94	97	95
UFS-Net	93.63	93	100	96.39
Geliştirilen Model	98.21	100	100	100

Tablo 2. Aksoy ve çalışma arkadaşları tarafından yapılan çalışmanın sonuçları.

Yapılan bir diğer çalışmada, Yangjie Xu ve diğerleri yalnızca yangın görüntülerini kullanarak tek sınıflı (one-class) bir yangın tespit modeli geliştirmiştir [15].

InDeepOCC adı verilen bu model, yangın sınıfına ait örneklerle eğitilmiş ve yangın olmayan durumlara dair herhangi bir veri kullanılmadan anomali tespiti yapabilme yeteneği kazandırılmıştır. Çalışmanın temel katkısı, yangın verilerinin çoğunlukla tek bir dağılım etrafında yoğunlaştığı gözlemi üzerine inşa edilen, açıklanabilir ve dar karar sınırları çizebilen bir yöntem sunmasıdır. Mevcut yöntemlerden farklı olarak, InDeepOCC modeli, yapay örnekleri daha sınırlı sayıda ve daha gerçekçi biçimde üretmektedir. Özellikle, isotropik komşuluk yerine anizotropik komşuluk kullanılarak, sınıf sınırlarının daha doğru ve esnek bir şekilde belirlenmesi sağlanmıştır. Çalışmada geliştirilen modelin performansı aşağıdaki gibi değerlendirilmiştir:

Veri Seti	Doğruluk (Accuracy)	F1 Skoru	True Positive Rate (TPR)	False Positive Rate (FPR)
Car-Fire	%98.33	98	%99.33	%2.67
Ind-Fire	%97.34	97	%96.67	%2.00
Ortalama	%97.84	98	%98.00	%2.34

Tablo 3. Yangjie Xu ve çalışma arkadaşları tarafından yapılan çalışmanın sonuçları.

Honglin Wan ve diğerlerinin [16] yaptığı çalışmada ise, YOLOv5 v7.0 tabanlı **YOLO-LFD** modeli kullanılarak yangın tespiti yapılmıştır. Modelde, DSConv, C2f-Light, C3CIB modülleri ve NWD loss fonksiyonu gibi çeşitli optimizasyonlar uygulanarak daha hafif ve hızlı bir yapı hedeflenmiştir. Bu optimizasyonlar, modelin özellikle kaynak kısıtlı cihazlarda, özellikle **drone'lar** gibi düşük donanımlı sistemlerde, gerçek zamanlı yangın tespiti uygulamalarına uygun olmasını sağlamıştır. Görüntü işleme sürecinde **DSConv** derinlemesine ayrılmış konvolüsyon işlemi kullanılarak hesaplama maliyeti düşürülmüş ve hız artırılmıştır. Ayrıca **C2f-Light** ve **C3CIB** modülleri modelin işlem hızını optimize etmek için tercih edilmiştir. Modelin performansını iyileştirmek amacıyla **NWD loss fonksiyonu** kullanılmış ve daha doğru tahminler elde edilmiştir. Çalışmanın sonuçları aşağıdaki gibidir:

Metrik	Değer
Doğruluk (Accuracy)	%98.5
F1 Skoru	0.94
Precision	0.95
Recall	0.93

Tablo 4. Honglin ve çalışma arkadaşları tarafından yapılan çalışmanın sonuçları.

Yapılan literatür taraması sonucu aşağıdaki tablo ile gösterilmiştir:

Çalışma	Model	Veri Seti	Doğruluk (%)	F1 Skoru	Kesinlik (Precision)	Duyarlılık (Recall)	Özellikler
Chen ve Arkadaşları [12]	Resnet18, Late Fusion (Hibrit)	FLAME2 (RGB/IR)	99.44	99.5	99.46	99.56s	RGB-termal füzyonu, Transfer Learning
Chen ve Arkadaşları [12]	MobileNetV2, Late Fusion (Hibrit)	FLAME2 (RGB/IR)	99.81	99.82	99.78	99.87	RGB-termal füzyonu, Transfer Learning
Chen ve Arkadaşları [12]	MobileNetV2, RGB	FLAME2 (RGB/IR)	99.91	99.92	99.9	99.93	RGB-termal füzyonu, Transfer Learning
Shi ve Arkadaşları [13]	YOLOv5m	İnternette Derlenen 7878 Görüntü	-	-	-	71.2	Arka plan iyileştirme
Shi ve Arkadaşları [13]	YOLOv5m + SAC (Switchable Atrous Convolution)	İnternette Derlenen 7878 Görüntü	-	-	-	73.7	Arka plan iyileştirme
Shi ve Arkadaşları [13]	YOLOv5m + SAC + Soft-NMS	İnternette Derlenen 7878 Görüntü	-	-	-	73.7	Duman ve alev tespiti iyileştirme
Shi ve Arkadaşları [13]	SPS – YOLOv5	İnternette Derlenen 7878 Görüntü	-	-	-	74.3	Hedef tespiti ve yanlış pozitif azaltma

Engin ve Kökhan [14]	VGG16	Kaggle Yangın Veri Seti (755 yangın, 244 yangın yok)	97.51	98	98.68	98.04	En iyi sonuç
Aksoy ve Arkadaşları [11]	SqueezeNet	FIRE-Dataset (755 yangın, 244 yangın yok)	96	100	96	98	Gelişmiş model
Yangjie Xu ve Arkadaşları [15]	InDeepOCC (One-Class)	Car-Fire, Ind-Fire	97.84	98	-	-	Anomali Tespiti
Honglin Wang ve Arkadaşları [16]	YOLO-LFD (YOLOv5 v7.0)	-	98.5	0.94	0.95	0.93	DSConv, C2f-Light, C3CIB, NWD loss
Wendell Balagot [17]	Xception	fire-dataset class 0 non-fire images class 1 fire images	89	class 0 (non-fire images): 0.92 class 1 (fire images): 0.80	-	-	-
Ashwin K Raghu [18]	CNN	fire-dataset	97	0.80	-	-	-
Baris Dincer [19]	Model 1 - CNN Model 2 – ANN Model 3- RCNN	fire-dataset class 0 fire images class 1 non-fire images	Model 1 - %63 Model 2 - %65 Model 3- %72	Model 1 (Class0 – 0.76) (Class1 – 0.21) Model 2 (class0 - 0.77) (Class1 - 0.26)			

				Model 3 (Class0 - 0.83) (Class1- 0.22)			
Alsayed [20]	VGG16	fire_dataset class 0 fire images class 1 non-fire images	%99	Class 0 - 0.99 Class 1 - 0.98			
Aesedeu [21]	CNN	fire_images	%100	1.0			
Ritu Pande [22]	Model 1 - ResNet50 Model 2 – VGG16	Fire Detection from CCTV	Model 1 - %97.11 Model 2- %97				
Parthiv Akilesh [23]	CNN	Fire Dataset	94	0.90			
CHEMAMA Samuel [24]	CNN	Fire Datas class 0 fire images class 1 non-fire images	95	Class 0- 0.92 Class 1- 0.97			

Tablo 5. Literatürdeki çalışmaların sonuçları.

3. İş-Zaman Çizelgesi

İP No	İş Paketlerinin Adı ve Hedefleri	Kim(ler) Tarafından Gerçekleştirileceği	Zaman Aralığı (.... Ay)	Başarı Ölçütü ve Projenin Başarısına Katkısı
1	Veri setlerinin elde edilmesi ve düzenlenmesi	Dilara Karadaş	1-2 ay	Yeterli sayıda ve konuya özgün veri setlerinin toplanması, veri kalitesinin artırılması ve düzenlenmesi, modellerin eğitimi ve sonuçlarının başarısı için kritik bir öneme sahiptir. Kaliteli ve doğru veri setleri, model eğitiminin etkinliğini artırır, bu da sonuçların güvenilirliğini ve genel projenin başarısını olumlu yönde etkiler.
2	Lojistik Regresyon (LR), Destek Vektör Makineleri (DVM, Doğrusal Ayrım Analizi (DAA), Rastgele Orman (RO), Aşırı Gradyan Artışı (XGB), AdaBoost (AB), VGG16, AlexNet, InceptionV3 ve Resnet50 modelleri üzerinde veri setlerinin eğitilmesi ve test edilmesi	Dilara Karadaş, Deniz Uzunyol	1-3 ay	Bu iş paketi, mevcut yangın tespit yöntemlerini geliştirmek ve optimize etmek için kritik bir aşamadır. Modellerin eğitilmesi ve test edilmesi sayesinde, en iyi performansı gösteren algoritmalar belirlenerek, yangınların erken tespiti konusunda daha etkili ve güvenilir bir çözüm sunulması amaçlanmaktadır. Aynı zamanda, farklı yöntemlerin karşılaştırılması, projenin genel başarısını artırarak, daha geniş alanlarda uygulanabilirlik sağlamakta katkıda bulunacaktır.
3	Yangın tespiti için gerekli video veri setinin toplanması, etiketlenmesi ve düzenlenmesi	Deniz Uzunyol	1-2 ay	Bu iş paketi, yangın tespit sisteminin temelini oluşturacak olan veri setinin hazırlanmasını amaçlamaktadır. Yangınların tespitinde video verileri kritik öneme sahiptir; çünkü bu veriler, makine öğrenimi ve derin öğrenme algoritmalarının eğitilmesi için gereklidir. Kaliteli ve çeşitlendirilmiş bir video veri seti, modellerin daha iyi öğrenmesine ve daha doğru sonuçlar üretmesine olanak tanır. Ayrıca, farklı durumlar ve koşullarda yangınların nasıl görüldüğünü anlamaya yardımcı olarak, sistemin genel güvenilirliğini artırır. Böylece, yangınların erken tespiti ve zamanında müdahale için etkili bir sistemin geliştirilmesine önemli bir katkı sağlayacaktır.
4	Derin öğrenme modellerinden YOLO ve versiyonlarının	Dilara Karadaş, Deniz Uzunyol	1-3 ay	YOLO, anlık görüntü analizi yeteneği sayesinde, video akışları üzerinde hızlı ve doğru nesne tespiti yapma kapasitesine sahiptir. Yangınların erken tespiti için kritik

	video veri seti üzerinde eğitilmesi ve test edilmesi			olan bu özellik, gerçek zamanlı izleme sistemlerinin geliştirilmesine olanak tanıyacaktır.
5	Test sonuçlarının raporlanması ve bilimsel bir yayın olarak hazırlanması	Dilara Karadaş, Deniz Uzunyol	1-2 ay	Projede elde edilen bulguların doğru bir şekilde analiz edilmesi, araştırmanın güvenilirliğini artıracak ve bilimsel bir yayında paylaşılması araştırmanın görünürlüğünü artırarak, benzer çalışmalara referans olacaktır. Ayrıca, yangın tespit sistemlerinin geliştirilmesine katkıda bulunarak, bu alandaki uygulayıcılara ve araştırmacılara değerli bilgiler sunacaktır.

4. Deneysel Çalışmalar

Makine öğrenimi ve derin öğrenme tekniklerinin temel prensipleri üzerine yapılan bu çalışmada, Anaconda platformu ve Spyder IDE kullanılarak veri analizi ve model geliştirme süreçleri gerçekleştirilmiştir. Denetimli öğrenmede regresyon, karar ağaçları ve destek vektör makineleri; denetimsiz öğrenmede ise kümeleme algoritmaları ve PCA yöntemleri incelenmiştir. Sinir ağı modellerinin giriş, gizli ve çıkış katmanları detaylı şekilde ele alınarak CNN ve RNN gibi mimariler araştırılmıştır. Çalışma, yapay zeka projelerinde bu yöntemlerin teorik temellerini anlamaya ve uygulamalara yönelik bir perspektif sunmuştur. Bu çalışmanın erken aşamalarında, bilgisayarlı görü teknikleri kullanılarak video görüntülerinden gerçek zamanlı yangın tespiti için bir algoritma geliştirilmiştir. Geliştirilen algoritmada temel görüntü işleme teknikleri kullanılmıştır. İlk aşamada, gelen video çerçeveleri BGR renk uzayından HSV renk uzayına dönüştürülmektedir. HSV renk uzayı, yangının karakteristik kırmızı ve turuncu tonlarını daha hassas bir şekilde ayırt etmeye olanak sağlamaktadır. Renk tespiti için iki farklı kırmızı ton aralığı (0-20 ve 160-180 derece) tanımlanmış ve bu aralıklar birleştirilerek daha kapsamlı bir yangın renk spektrumu oluşturulmuştur.

Performans ve işlem hızını artırmak için video çerçeveleri küçük boyuta (640x360 piksel) indirilmektedir. Morfolojik görüntü işleme teknikleri kullanılarak gürültü azaltılmakta ve kontür netleştirme işlemleri gerçekleştirilmektedir. Özellikle dilate ve morfolojik kapatma (close) işlemleri, yangın bölgelerinin daha belirgin hale gelmesini sağlamaktadır. Kontür tespiti aşamasında, alan ve şekil kriterleri uygulanmaktadır. 50 ile 5000 piksel arasındaki kontürler değerlendirilmekte ve en/boy oranı 0.3 ile 3.0 arasında olan kontürler yangın adayı olarak seçilmektedir. Bu kriterler, yanlış pozitif tespitleri minimize etmek ve gerçek yangın bölgelerini daha doğru tespit etmek amacıyla belirlenmiştir. Algoritmanın temel bileşenleri Python programlama dili ve OpenCV ile NumPy kütüphaneleri kullanılarak geliştirilmiştir. Gerçek zamanlı çalışma özelliği ve düşük hesaplama maliyeti, sistemin teknik altyapısını oluşturmaktadır.

Yapılan deneysel çalışmalarda, mevcut algoritmanın ciddi sınırlamaları tespit edilmiştir. Özellikle tarla, kırmızı nesneler ve belirli arka plan görüntüleri sıklıkla yanlış pozitif yangın tespitlerine neden olmaktadır. Renk ve kontür tabanlı basit görüntü işleme teknikleri, karmaşık görsel senaryolarda yetersiz kalmaktadır. Sonuç olarak, mevcut yaklaşım tatmin edici bir performans sergilememektedir. Algoritmadaki temel sorunların üstesinden gelmek için derin öğrenme teknikleri, özellikle

Evrişimsel Sinir Ağları (CNN) ile bir model eğitilmesi zorunlu görülmektedir. Derin öğrenme modelleri, görüntülerdeki karmaşık örüntüleri ve yangın özelliklerini daha doğru bir şekilde öğrenme ve ayırt etme potansiyeline sahiptir. Gelecek çalışmaların, büyük ve çeşitli bir veri seti üzerinde eğitilmiş derin öğrenme modellerine odaklanması önerilmektedir.

Yapılan bir diğer çalışmada, **Kaggle Forest Fire Images Dataset** kullanılarak yangın ve duman tespiti üzerine geliştirilmiş hafif ve güçlü bir derin öğrenme modeli olan **SE-VGG16** tanıtılmıştır [25]. Veri seti, yangın ve yangın olmayan görüntülerden oluşmakta olup eğitim, doğrulama ve test olarak üçe ayrılmış ve ön işleme tabi tutulmuştur. SE-VGG16 modeli, VGG16 mimarisi üzerine **Squeeze-and-Excitation blokları** eklenerek geliştirilmiştir. Model, GPU destekli eğitimle optimize edilmiş, **Adam optimizasyon algoritması** ve **Cross-Entropy kayıp fonksiyonu** kullanılarak 10 epoch boyunca eğitilmiştir. Aşağıdaki tabloda, SE-VGG16 modelinin diğer yaygın derin öğrenme modelleriyle kıyaslandığında elde ettiği üstün performans görülmektedir:

Model	Doğruluk (Accuracy)	Recall	Precision	F1-Skoru
ResNet-50	88%	86%	84.6%	85.3%
VGG-16	89%	87.2%	85%	86.1%
DenseNet121	87%	85.7%	82%	83.8%
SE-VGG16 (Yapılan Çalışma)	98%	98.5%	97%	98%

Tablo 6. Yapılan çalışmanın deneysel sonuçları.


Yaptığımız bir diğer çalışmada, yangın tespiti amacıyla kullanılan **Fire-Dataset** üzerinde **SqueezeNet** mimarisi uygulanmıştır. Modelin eğitimi ve değerlendirilmesi sürecinde, **Aksoy ve arkadaşlarının (2022)** yürüttüğü çalışmada kullanılan hiperparametreler esas alınmıştır. Böylece, yapılan karşılaştırmalı analizlerin geçerliliği ve tutarlılığı sağlanmıştır.

Aksoy ve arkadaşlarının çalışmasında belirtilen hiperparametreler şunlardır:

- **Epoch Sayısı: 10**
Modelin tüm eğitim verisi üzerinde 10 kez eğitilmesini sağlamaktadır. Bu tekrarlar, modelin daha iyi genelleştirme yapabilmesi açısından önemlidir.
- **Öğrenme Oranı (Learning Rate): 0.005**
Ağırlıkların güncellenme hızını belirleyen bu değer, modelin ne kadar agresif veya temkinli öğreneceğini kontrol eder.
- **Optimizasyon Algoritması: Adam**
Momentum dayalı adaptif öğrenme oranı kullanan bu algoritma, öğrenme sürecini hem hızlandırmakta hem de daha kararlı hale getirmektedir.
- **Kayıp Fonksiyonu: sparse_categorical_crossentropy**
Etiketlerin tamsayı biçiminde olması ve sınıf sayısının sınırlı olması durumlarında tercih edilen bu fonksiyon, sınıflar arası farkları etkili biçimde ölçmektedir.
- **Veri Ayrımı: %80 Eğitim / %20 Test**
Veri setinin %80'i modelin eğitimi için, %20'si ise modelin doğrulama ve test işlemleri için ayrılmıştır.
- **Batch Size: (Çalışmada belirtilmemiştir)**
Ancak yaygın pratiklere uygun olarak biz bu çalışmada batch size'ı 32 olarak belirledik.

Model, 10 epoch boyunca eğitilmiştir. Aşağıdaki tabloda, her bir epoch sonunda hesaplanan eğitim ve doğrulama kayıpları (loss) ile doğruluk (accuracy) değerleri yer almaktadır. Eğitim süreci boyunca modelin doğruluk oranı kademeli olarak artarken, doğrulama kaybı da istikrarlı bir şekilde azalmıştır. Bu durum, modelin öğrenme kapasitesinin iyi olduğu ve aşırı öğrenme (overfitting) problemi yaşanmadığını göstermektedir.

Epoch	Eğitim Kayıp (Loss)	Eğitim Doğruluğu (Accuracy)	Doğrulama Kayıp (Val Loss)	Doğrulama Doğruluğu (Val Accuracy)
1	0.6923	0.60	0.6890	0.62
2	0.6812	0.68	0.6754	0.66
3	0.6505	0.74	0.6381	0.70
4	0.6153	0.78	0.6020	0.73
5	0.5807	0.81	0.5712	0.76
6	0.5423	0.84	0.5290	0.79
7	0.5041	0.87	0.4925	0.82
8	0.4670	0.89	0.4611	0.85
9	0.4322	0.91	0.4303	0.87
10	0.3980	0.93	0.4032	0.89



Yapılan çalışmanın grafikleri ve karmaşıklık matrisi yukarıda verilmiştir.

Performans Metrikleri	Bu Çalışma	Aksoy ve Ark. (2022)
Doğruluk (Accuracy)	%94.5	%96
Duyarlılık (Recall)	%92.3	%98
Özgüllük (Specificity)	%96.1	%89
Kesinlik (Precision)	%94.6	%96
F1-Skoru	%93.4	-

Tablo 7. Yapılan her iki çalışmanın karşılaştırmalı sonuçları.

Karşılaştırmalı olarak değerlendirildiğinde, Aksoy ve arkadaşlarının çalışmasında duyarlılık oranı (%98) oldukça yüksek olup yangın sınıfının başarıyla tespit edildiğini göstermektedir. Ancak bu çalışmada daha yüksek bir özgüllük değeri (%96.1) elde edilmiş olup bu da yangın olmayan görüntülerin yanlış alarm üretmeden doğru şekilde tanımlandığını göstermektedir. Kesinlik açısından benzer değerler gözlemlenmiştir (%96'ya karşılık %94.6). Ayrıca bu çalışmada ek olarak **F1-skoru %93.4** olarak hesaplanmış ve modelin dengeli bir başarı gösterdiği ortaya konmuştur.

4.1.Yangın Tespiti İçin Derin Öğrenme Modelleri: VGG16 ve ResNet50

Performans Karşılaştırması

Bu çalışmada, yangın tespiti yapmak amacıyla iki farklı derin öğrenme modelinin performansı karşılaştırılmıştır. İlk olarak, **VGG16** mimarisi ile bir model oluşturulmuş ve ardından bu modelin performansı **ResNet50** tabanlı model ile karşılaştırılmıştır. Her iki modelin de doğruluk, F1 skoru, karışıklık matrisi ve sınıflandırma raporu gibi metrikler üzerinden değerlendirilmesi yapılmıştır.

Model Mimarilerinin Teorik Altyapısı

VGG16, 16 katmandan oluşan derin bir konvolüsyonel sinir ağıdır ve görsel tanıma problemleri için yaygın olarak kullanılır. Bu model, özellikle konvolüsyonel katmanlarındaki derinlik ve yüksek çözünürlüklü görüntüleri işlemesiyle dikkat çeker. Ancak, **VGG16**'nın mimarisi, derin ağların eğitilmesinde karşılaşılan bazı zorluklar nedeniyle daha yavaş öğrenme süreçlerine ve daha fazla hesaplama gücüne ihtiyaç duyabilir.

ResNet50 mimarisi ise, 50 katmanlı yapısıyla "**residual learning**" yaklaşımını kullanmaktadır. Bu yaklaşım, derin ağlarda sıkça karşılaşılan gradyan kaybı problemini minimize ederek, daha derin ağların eğitilmesini mümkün kılmaktadır [12]. Residual bağlantılar sayesinde katmanlar arası öğrenme süreci optimize edilmekte ve model performansı artırılmaktadır.

4.2.Model Özelleştirme ve Eğitim Süreci

Her iki model de **ImageNet** veritabanı üzerinde önceden eğitilmiş ağırlıklarla kullanılmış ve sonrasında yangın tespiti gibi ikili sınıflandırma problemleri için özelleştirilmiştir. Özelleştirme süreci, her iki modelin son katmanlarının çıkarılmasını ve yeni, problem spesifik katmanların eklenmesini içermektedir:

- **VGG16** ve **ResNet50**'de de konvolüsyonel katmanlardan çıkan özelliklerin özetlenmesi amacıyla **GlobalAveragePooling2D** katmanı eklenmiştir.
- Aşırı öğrenmeyi önlemek için her iki modelde de **Dropout** katmanları kullanılmıştır.
- Son olarak, her iki model de **sigmoid** aktivasyon fonksiyonu ile çıkış yaparak ikili sınıflandırma işlemi gerçekleştirmiştir.

4.3.VGG16 VE ResNet50 Performans Analizi ve Değerlendirme

Her iki model de benzer bir eğitim sürecine tabi tutulmuştur:

- **Adam optimizasyon algoritması** kullanılmış ve öğrenme oranı **0.0001** olarak belirlenmiştir.
- Modelin eğitimi sırasında, **early stopping** (erken durdurma) tekniği uygulanarak, doğrulama kaybı 5 epoch boyunca iyileşmediğinde eğitim süreci sonlandırılmıştır.
- Eğitimde kullanılan veri kümesi, **train**, **validation** ve **test** olarak üç ana gruba ayrılmıştır. Veri artırma (data augmentation) işlemleri, eğitim verilerine uygulanmış ve test doğruluğu ile modelin genel performansı değerlendirilmiştir.

Her iki modelin test veri kümesi üzerinde elde edilen performans sonuçları aşağıdaki gibidir:

Epoch	Zaman/Adım	Eğitim Doğruluğu	Eğitim kaybı	Doğrulama Doğruluğu	Doğrulama kaybı
1/20	350 ms/step	0.5164	0.7781	0.5190	0.6670

2/20	347ms/step	0.5592	0.7115	0.5600	0.6457
3/20	347ms/step	0.5865	0.6817	0.6300	0.6291
4/20	345ms/step	0.6021	0.6555	0.6695	0.6139
5/20	343ms/step	0.6302	0.6380	0.6935	0.6013
6/20	348ms/step	0.6484	0.6204	0.6970	0.5891
7/20	347ms/step	0.6735	0.6005	0.7405	0.5720
8/20	342ms/step	0.6802	0.5904	0.7290	0.5640
9/20	336ms/step	0.6935	0.5745	0.7730	0.5454
10/20	341ms/step	0.7017	0.5608	0.7480	0.5451
11/20	345ms/step	0.7089	0.5523	0.7615	0.5327
12/20	342ms/step	0.7103	0.5468	0.8040	0.5121
13/20	340ms/step	0.7150	0.5434	0.8185	0.5011
14/20	344ms/step	0.7235	0.5413	0.8095	0.4969
15/20	341ms/step	0.7114	0.5393	0.7985	0.4907
16/20	341ms/step	0.7428	0.5178	0.8125	0.4784
17/20	339ms/step	0.7415	0.5213	0.8135	0.4714
18/20	338ms/step	0.7491	0.5153	0.7845	0.4666
19/20	342ms/step	0.7342	0.5205	0.8105	0.4666
20/20	335ms/step	0.7549	0.5023	0.8240	0.4563

Bu çıktılar, modelin eğitim süreci boyunca her epoch (dönem) için elde edilen eğitim ve doğrulama doğruluğu ile kaybı (loss) değerlerinin özetini sunmaktadır. Bu veriler, modelin öğrenme ve genelleme performansını değerlendirmek amacıyla kullanılır.

63/63	
Test Loss	0.4666099548339844
Test Accuracy	0.8159999847412109

Bu çıktılar, modelin **test veri kümesi** üzerindeki performansını değerlendiren iki önemli metriği yansıtmaktadır:

- ❑ **Test kaybı:** 0.4666'lık değeri, modelin test veri kümesi üzerindeki hatasının ortalama büyüklüğünü belirtirken, daha düşük değerler daha iyi bir model performansını işaret eder.
- ❑ **Test doğruluğu:** %81.60'lık doğruluk oranı, modelin test verisi üzerinde doğru tahmin yapma başarısını yansıtır ve modelin genelleme yeteneğinin güçlü olduğunu gösterir.

	Precision	Recall	F1-score	Support
0	0.75	0.96	0.84	1000
1	0.94	0.67	0.79	1000

Accuracy			0.82	2000
Nacro avg	0.84	0.82	0.81	2000
Weighted avg	0.84	0.82	0.81	2000

Bu tablo, modelin sınıflandırma performansını daha ayrıntılı bir şekilde değerlendiren **precision, recall, F1-score** ve **support** gibi metrikleri içermektedir. Bu metrikler, modelin her bir sınıf için ne kadar başarılı olduğunu ve genel performansını anlamak için kullanılır.

Bu metrikler, modelin **Sınıf 0**'da yüksek hassasiyetle doğru tahminler yaparken, **Sınıf 1**'de bazı doğru pozitifleri kaçırdığına işaret etmektedir. Modelin genel doğruluğu **%82** iken, **Sınıf 1**'deki daha düşük recall değeri, bu sınıf için performansın iyileştirilebileceğini gösteriyor. Ancak modelin genel performansı, yüksek precision ve iyi F1-score ile oldukça başarılıdır.

True Positive [960]	False Negative [40]
False Positive [328]	True Negative [672]

Bu sonuçlar, modelin performansını değerlendirmeye yönelik önemli bilgileri sunar:

- **960 True Positives:** Model, yangın var durumunu **%96** doğrulukla tespit etmiştir. Bu yüksek bir başarı oranıdır.
- **40 False Negatives:** Model, yangın var olduğu halde **%4**'lük bir hata ile yanlışlıkla yangın yok olarak sınıflandırmıştır. Bu oran oldukça düşük olup, modelin yangın tespitindeki doğruluğunun yüksek olduğunu gösterir.
- **328 False Positives:** Model, yangın yok olduğu halde **%24.5**'lik bir hata oranı ile yanlışlıkla yangın var olarak sınıflandırmıştır. Bu, modelin yanlış alarm verme oranıdır ve iyileştirilmesi gereken bir alanı işaret eder.
- **672 True Negatives:** Model, yangın yok durumunu **%67.2** doğrulukla doğru bir şekilde tespit etmiştir.

Bu metrikler, modelin genellikle doğru sonuçlar verdiğini ancak bazı yanlış pozitif tahminler yaptığına, dolayısıyla **false positive** oranının iyileştirilmesi gerektiğine işaret etmektedir.

4.4.YOLOv11 Performans Değerlendirmesi

Bu bölümde, yangın tespiti projemizde YOLOv11 modeli kullanılarak görüntü tabanlı nesne tespiti gerçekleştirilmiştir. YOLOv11'in, hızlı ve doğru tespit yeteneği ile yangın sınıflandırmasında başarılı olduğu literatürle kanıtlanmıştır. Model, mevcut veri seti üzerinde eğitilmiş ve sınırlayıcı kutu kaybı, dağılım temeli kaybı ve sınıflandırma metrikleriyle değerlendirilmiştir. Ayrıca, görüntülerdeki yangın alanlarını daha hassas tespit etmek için kenar bulma algoritması kullanılmış, bu sayede modelin tespit doğruluğu artırılmıştır.

Epoch	Zaman/Adım	Sınırlayıcı kutu kaybı	Sınıflandırma kaybı	Dağılım temeli kaybı	Instances
4/20	553ms/step	1.572	1.807	1.551	25
5/20	449ms/step	1.528	1.709	1.504	26

6/20	447ms/step	1.454	1.564	1.479	21
7/20	445ms/step	1.446	1.495	1.471	29
8/20	436ms/step	1.434	1.409	1.432	41
9/20	436ms/step	1.405	1.396	1.426	23
10/20	434ms/step	1.378	1.311	1.418	25
11/20	438ms/step	1.357	1.278	1.407	26
12/20	437ms/step	1.360	1.282	1.403	25
13/20	435ms/step	1.317	1.243	1.378	38
14/20	433ms/step	1.325	1.242	1.360	36
15/20	435ms/step	1.322	1.221	1.378	42
16/20	434ms/step	1.297	1.145	1.364	34
17/20	431ms/step	1.308	1.233	1.373	17
18/20	439ms/step	1.242	1.161	1.327	22
19/20	438ms/step	1.285	1.153	1.343	36
20/20	435ms/step	1.285	1.141	1.319	35

Bu çıktılar, modelin eğitim süreci boyunca her epoch (dönem) için elde edilen sınıflandırma kaybı ve sınırlayıcı kutu kaybı, dağılım temeli kaybı ile (loss) değerlerinin özetini sunmaktadır. Bu veriler, modelin öğrenme ve genelleme performansını değerlendirmek amacıyla kullanılır.

	Precision	Recall	F1-score	Support
0	0.905	0.821	0.94	153
1	0.980	0.86106	0.96	46

Modelin değerlendirme sonuçlarına göre, ortalama doğruluk (Precision) 0.905, ortalama geri çağırma (Recall) 0.821 ve ortalama ortalama hassasiyet (mAP) 0.7978 olarak hesaplanmıştır. Ayrıca, modelin işlem süresi, görüntü başına preprocess 0.6 ms, inference 3.9 ms, loss hesaplama 0.0 ms ve postprocess 1.5 ms olarak kaydedilmiştir. Bu sonuçlar, modelin yüksek doğruluğa sahip ve hızlı bir şekilde çalıştığını göstermektedir.

modelin daha çeşitli yangın senaryolarında da doğru çalışabilmesi için eğitim veri setine farklı açılardan ve ortamlardan yangın görüntüleri eklenmelidir. Ayrıca, kenar bulma algoritmasının doğruluğunu artırmak amacıyla **Canny Edge Detection** veya **Sobel Operatörü** gibi gelişmiş teknikler kullanılabilir. Modelin hızını daha da artırmak ve gerçek zamanlı kullanımını sağlamak için GPU optimizasyonları veya daha hızlı nesne tespiti modelleri (örneğin, YOLOv8) incelenebilir. Bunun yanı sıra, geliştirilen modelin bir yangın erken uyarı sistemi ile entegre edilmesi, yangınların hızlı bir şekilde tespit edilmesini ve gerekli müdahalelerin zamanında yapılmasını sağlayabilir. Son olarak, modelin performansının sürekli olarak izlenmesi ve yeni yangın verileri ile düzenli olarak yeniden eğitilmesi, etkinliğinin korunması açısından kritik öneme sahiptir.

5. Deneysel Çalışmalar

Bu çalışmada, orman yangınlarının daha erken ve güvenilir şekilde tespit edilebilmesi amacıyla mevcut yapay zeka tabanlı modele görüntü işleme teknikleri entegre edilmiştir. Bu kapsamda, yangın bölgelerinin sınırlayıcı kenar yapılarının daha belirgin hale getirilmesi hedeflenmiş ve bu doğrultuda Sobel filtresi uygulanmıştır. Sobel filtresi, yatay ve dikey gradyanları hesaplayarak görüntüdeki kenar yapılarını ortaya çıkarmakta ve yangın alanlarının yapısal özelliklerini daha açık bir şekilde görünür hâle getirmektedir. Görüntü işleme adımının ardından model, 120 epoch boyunca eğitilmiş ve test sürecinde toplam 25 farklı görüntü kullanılmıştır. Deneysel sonuçlar incelendiğinde, modelin doğruluk (accuracy) değerinin yüksek kaldığı ve genel sınıflandırma başarısının korunduğu gözlemlenmiştir. Ancak F1-score değerinde önceki durumlara kıyasla bir miktar düşüş meydana gelmiştir. Bu durum, modelin özellikle pozitif sınıf olan yangın bölgelerini tespit etme performansında hassasiyet kaybı yaşadığını göstermektedir. Dolayısıyla modelin genel doğruluğu etkilenmemiş olsa da, sınıf dengesine dayalı metriklerde düşüş gözlenmiştir.

Deneysel çalışmayı görsel olarak desteklemek amacıyla, aşağıda modelin çeşitli görüntüler üzerindeki tahmin sonuçlarına ait örneklerle yer verilmiştir. Bu örneklerde, orijinal görüntüler, Sobel filtresi uygulanmış halleri ve modelin yangın tespiti çıktıları karşılaştırmalı biçimde sunulmuştur. Görseller, modelin kenar vurgulama sonrası nasıl çalıştığını ve yangın alanlarını hangi bölgelerde başarıyla tespit ettiğini somut olarak ortaya koymaktadır.

image 1/1 /kaggle/input/Fire-detection/Fire-Detection/test/images/Img_6988.jpg.rf.ac04114306891a01e0f727802c54234e.jpg: 640x640 2 fires, 9.1ms
Speed: 2.2ms preprocess, 9.1ms inference, 1.5ms postprocess per image at shape (1, 3, 640, 640)
Results saved to runs/detect/predict



Şekil 5. Sobel filtresi uygulanmış görüntü

image 1/1 /kaggle/input/Fire-detection/Fire-Detection/test/images/FireDataThree13254.png.rf.34fcf8f6f2b1815b19e5c739ad139357.jpg: 640x640 1 fire, 9.5ms
Speed: 2.2ms preprocess, 9.5ms inference, 1.5ms postprocess per image at shape (1, 3, 640, 640)
Results saved to runs/detect/predict



Şekil 6. Sobel filtresi uygulanmış görüntü

Image 1/1 /raggle/input/fire-detection/test/images/img_25980.jpg.rf.130790eda488b803897cb8eda64cfa4.jpg: 640x640 1 fire, 12.4ms
Speed: 2.9ms preprocess, 12.4ms inference, 2.0ms postprocess per image at shape (1, 3, 640, 640)
Results saved to runs/detect/predict



Şekil 7. Sobel filtresi uygulanmış görüntü

6. Sonuç ve Öneriler

Bu çalışmada gerçekleştirilen deneyler, görüntü işleme tekniklerinden Sobel filtresinin yapay zeka tabanlı orman yangını tespit sistemine entegrasyonunun model performansına çeşitli etkilerde bulunduğunu göstermektedir. Sobel filtresi sayesinde görüntüdeki yapısal ayrıntılar vurgulanarak modelin görsel veriyi daha nitelikli analiz etmesi sağlanmıştır. Eğitim sonrası yapılan testlerde doğruluk değerlerinin yüksek kalması, modelin genel sınıflandırma gücünü koruduğunu göstermektedir.

Bununla birlikte, F1-score değerinde gözlemlenen düşüş, özellikle pozitif sınıfların (yangın içeren bölgeler) tanınmasında duyarlılık düzeyinin azaldığını işaret etmektedir. Bu durum, sınıf dengesinin model başarımı üzerindeki kritik etkisini ortaya koymaktadır. Dolayısıyla, yalnızca doğruluk metriğiyle değerlendirme yapılmaması, F1-score ve benzeri denge odaklı metriklerin de dikkate alınması gerektiği anlaşılmaktadır.

Modelin başarımını somut biçimde ortaya koymak adına, deneysel çalışmalarda kullanılan bazı test görüntüleri görsel olarak da analiz edilmiştir. Şekil 6’da yer alan örnekte, Sobel filtresi uygulanmış bir görüntü üzerinde modelin yangın tespiti sonucu gösterilmektedir. Görüntüde kenar yapılarının belirginleşmesiyle birlikte, modelin “fire” etiketini %73.27 güven skoru ile doğru şekilde tahmin ettiği gözlemlenmektedir. Görsel analizler, özellikle yangın alanlarının çevresel yapılarla olan sınırlarının daha net belirlenmesinin modelin karar mekanizmasını desteklediğini göstermektedir.

İlerleyen çalışmalarda, sınıf dengesini iyileştirmeye yönelik veri artırma tekniklerinin kullanılması, modelin pozitif sınıflara karşı duyarlılığını artırabilir. Ayrıca hiperparametre optimizasyonu, farklı kenar tespit filtrelerinin (örneğin Canny, Laplacian) karşılaştırılması ve daha geniş veri setleriyle yapılacak deneyler sistemin genel başarımını önemli ölçüde artıracaktır.

7. Sonuç ve Öneriler

Sonuçlar, modelin **yangın tespiti** görevinde genel olarak başarılı olduğunu, ancak belirli alanlarda iyileştirme yapılması gerektiğini göstermektedir. Modelin **Sınıf 0**'da yüksek bir recall değerine sahip olması, yangın yok durumlarının doğru şekilde tespit edilmesinin büyük ölçüde başarılı olduğunu gösterir. Bununla birlikte, **Sınıf 1**'deki **false negative** oranı, bazı yangın vakalarının kaçırılmasına yol açmaktadır, bu da modelin **recall** değerinin düşmesine neden olmuştur. Modelin **false positive** oranı da göze çarpmaktadır. **Yangın yok** olan örneklerin yanlışlıkla **yangın var** olarak sınıflandırılması, yanlış alarmlar riskini artırmaktadır. Bu durum, modelin doğruluğunu etkileyebilir ve iyileştirilmesi gereken bir alandır.

Sonuç olarak, modelin genel başarısı **%81.6** doğruluk oranı ve yüksek **precision** değeri ile güçlüdür, ancak **false positive** ve **false negative** oranlarının azaltılması için daha fazla veri ve modelin hyperparametre optimizasyonu gerekmektedir. Ayrıca, **Sınıf 1** için daha fazla hassasiyet elde edebilmek amacıyla modelin yeniden eğitilmesi ve sınıflandırma eşik değerinin düzenlenmesi önerilmektedir.

SqueezeNet mimarisinin, yangın tespitinde doğruluk oranı **%94.5** olarak elde edilmiş olup, bu oran modelin genel doğruluğunu yansıtmaktadır. Ayrıca duyarlılık (recall) değeri **%92.3** olarak belirlenmiş, bu da modelin yangın gibi pozitif sınıfları doğru bir şekilde tespit etme konusundaki etkinliğini göstermektedir. Modelin yanlış pozitif oranlarını azaltmadaki başarısını gösteren özgüllük (specificity) değeri ise **%96.1** olarak hesaplanmıştır. Bunun yanı sıra, modelin pozitif sınıfları ne kadar doğru sınıflandırdığını gösteren F1-Skoru **%93.4** olarak elde edilmiştir.

KAYNAKLAR

- [1] Orman Genel Müdürlüğü. (2020). Türkiye Orman Varlığı 2020. www.ogm.gov.tr
- [2] Tarım ve Orman Bakanlığı, Orman Genel Müdürlüğü. (2023).
- [3] International Technical Committee for the Prevention and Extinction of Fire (CTIF). (2024). World Fire Statistics, Report No. 27. <https://www.ctif.org/reports>
- [4] Nelson, J. (2020, June 26). Geoscience Australia's Oliver Discusses Use of Landsat during Country's Historic Fires. United States Geological Survey. Retrieved August 12, 2020.
- [5] Hitch, G. (2020, May 26). Bushfire royal commission hears that Black Summer smoke killed nearly 450 people. <https://www.abc.net.au>
- [6] Gourlay, C., Leslie, T., Martino, M., & Spraggon, B. (2020, February 19). From a single lightning strike to Australia's largest bushfire. ABC News. Retrieved February 21, 2020.
- [7] Bott, L. M., & Fastenrath, S. (2020). Australian Bushfires. Herausgegeben im Namen der Gesellschaft für Australienstudien von Henriette von Holleuffer, Hamburg, Germany, 33, 127.
- [8] Gissing, A., Timms, M., Browning, S., Crompton, R., & McAneney, J. (2021). Compound natural disasters in Australia: A historical analysis. *Environmental Hazards*, 21(2), 159–173. <https://doi.org/10.1080/17477891.2021.1932405>
- [9] European Forest Fire Information System (EFFIS). (n.d.). EFFIS Statistics. Copernicus Emergency Management Service. Retrieved October 22, 2024, from <https://forest-fire.emergency.copernicus.eu/apps/effis.statistics>
- [10] European Forest Fire Information System (EFFIS). (2022). Forest Fires in Europe, Middle East and North Africa.
- [11] Aksoy, B., Korucu, K., Çalışkan, Ö., & Osmanbey, Ş. (2021). İnsansız hava aracı ile görüntü işleme ve yapay zekâ teknikleri kullanılarak yangın tespiti: Örnek bir uygulama. *Düzce Üniversitesi Bilim ve Teknoloji Dergisi*, 9(6), 112–122.
- [12] Chen, X., et al. (2022). Wildland fire detection and monitoring using a drone-collected RGB/IR image dataset. *IEEE Access*, 10, 121301–121317.
- [13] Shi, P., Lu, J., Wang, Q., Zhang, Y., Kuang, L., & Kan, X. (2023). An efficient forest fire detection algorithm using improved YOLOv5. *Forests*, 14(2440). <https://doi.org/10.3390/f14122440>
- [14] Engin, M. A., & Kökhan, S. (2024). İnsansız hava araçları ile orman yangınlarının tespitinde görüntü işleme ve yapay zekâ tabanlı otomatik bir model. *DÜBİTED*, 12(2), 762–775. <https://doi.org/10.29130/dubited.1103375>
- [15] Xu, Y., et al. (2025). Interpretable deep one-class model for forest fire detection. *Expert Systems with Applications*. <https://doi.org/10.1016/j.eswa.2025.127657>
- [16] Wang, H., Zhang, Y., & Zhu, C. (2024). YOLO-LFD: A lightweight and fast model for forest fire detection. *Journal of Artificial Intelligence and Image Processing*, 26(2), 123–134. <https://doi.org/10.1016/j.aiip.2024.11.012>
- [17] Dellllectron. (2025). Fire Detection - Computer Vision. Kaggle. <https://www.kaggle.com/code/dellllectron/fire-detection-computer-vision>
- [18] HoldMyKaggle. (n.d.). Fire Detection in Images. Kaggle. <https://www.kaggle.com/code/holdmykaggle/fire-detection-in-images>
- [19] Dinçer, B. (2023). Forest Fire Detection & Prediction (All Process). Kaggle. <https://www.kaggle.com/code/brsdincer/forest-fire-detection-prediction-all-process>

- [20] Sayed Ali, A. (2025). Fire Detection Using VGG16. Kaggle.
<https://www.kaggle.com/code/alsayedali/fire-detection-using-vgg16>
- [21] Aesedeu. (n.d.). Keras CNN - Fire Detection 1.00 Accuracy. Kaggle.
<https://www.kaggle.com/code/aesedeu/keras-cnn-fire-detection-1-00-accuracy>
- [22] Pande, R. (2020). Fire and Smoke Detection in CCTV Footage. Kaggle.
<https://www.kaggle.com/code/ritupande/fire-and-smoke-detection-in-cctv-footage>
- [23] Parthi, V. (2021). Fire Detection. Kaggle.
<https://www.kaggle.com/code/parthivakilesh/fire-detection>
- [24] Chemama, S. (2023). Fire Detection - 96% Accuracy. Kaggle.
<https://www.kaggle.com/code/chemamasamuel/fire-detection-96-accuracy>
- [25] Abdusalomov, A., et al. (2024). Enhanced Forest Fire and Smoke Detection Using SE-VGG16: A Lightweight and Robust Convolutional Neural Network. GitHub.
<https://github.com/SE-VGG16/Enhanced-Forest-Fire-and-Smoke-Detection-using-SE-VGG16-A-Lightweight-and-Robust-Convolutional-Neur>